Содержание

- 1. <u>Обзор (других) структур данных для быстрого поиска информации (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqyILg&expires=1593465693#overview)</u>
- 2. <u>Таблица с прямой адресацией (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html?</u> hash=okvx7MOSeqh5taAlDqylLg&expires=1593465693#directadressing).
- 3. Хэш-функция (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html?hash=okvx7MOSeqh5taAlDqylLg&expires=1593465693#hashfn)
- 4. Метод цепочек (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html?hash=okvx7MOSeqh5taAlDqyILg&expires=1593465693#chaindiff)
- Открытая адресация (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqylLg&expires=1593465693#open)
- 6. Виды пробинга (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html?hash=okvx7MOSegh5taAlDgylLg&expires=1593465693#prob)
- Домашняя работа (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqylLg&expires=1593465693#homework).

Обзор (других) структур данных для быстрого поиска информации

Список

- Список вообще не очень хорош для поиска в нем данных
- Поиск за O(n), просмотр всех элементов подряд

Отсортированный список/массив

- Все еще простейшая структура данных
- Нужно поддерживать в отсортированном виде $O(\log n)$ на вставку, если это список
- Поиск за $O(\log n)$

Heap

- O(1) на извлечение минимального/максимального элемента (используется в основном в этих целях)
- За O(log n) элементы добавляются и удаляются
- Искать определенный элемент по ключу неудобно (обход heap)

Binary search tree

- Поиск элемента, вставка, удаление из BST: O(h)
- O(h) не всегда равно $O(\log\,n)$, так как дерево не сбалансировано
- Есть возможность делать запросы "меньше/больше, чем..."

Red-Black tree

- Сбалансированное дерево с возможностью выполнять базовые операции за $O(\log n)$
- Есть возможность делать запросы "меньше/больше, чем..."

И другие

Поиск, удаление и вставка за О(1)

- Иногда запросы формата "больше/меньше" не требуются Скорость $O(\log\,n)$ недостаточно хороша

Таблицы с прямой адресацией

Ассоциативный массив

Ассоциативный массив - абстрактный тип данных, позволяющий хранить пары "ключзначение"И, реаслизующий операции

- Insert(key, value)
- Find(key)
- Remove(key)

Абстрактный - в данном случае значит, что конкретная реализация неизвестна, и мы сейчас рассмотрим несколько вариантов. Две пары значений с одинаковым ключом храниться не могут.

Простейший случай

Ключ однозначно указывает на ячейку памяти (например, ключ - это какое-то число). За O(1) можно обратиться к этой ячейке памяти и получить ассоциированное с ключом значение.

Сколько всего доступно памяти?

Адресация в массиве

- Размер адресуемой памяти у 32-битной архитектуры: $2^{32}=4294967296$ (~4 Гб) У 64-битной: $2^{64}=18446744073709551616$ (16 эксабайт, очень-очень много)

Представление таблицы с прямой адресацией

| $f: X \to X$ | Таблица с прямой адресацией | |
|---|-----------------------------|-------------------------|
| Множество | Индекс | Значение |
| всех ключей | ₂ 0 | / |
| <099> | 1 | ter Stegen |
| 0 27 | 2 | Semedo |
| | 3 | Pique |
| Используемые ключи < номера футболистов > | 4 | Rakitic |
| 1, 2, 3, 4,, 26 | 5 | Busquets |
| 1, 2, 0, 4,, 20 | | |
| 28 | 99 | / |
| 99 | Время поиска, в | ставки, удаления: О (1) |

Плюсы

- Простота реализацииПрактически нет дополнительных расходов на чтение, удаление и запись

Проблемы?

- Перерасход памяти: многие ячейки пустыОграничение по количеству возможных типов ключей

```
In [2]:
          barcelona table = fill team table(barcelona)
          barcelona_table.iloc[10:20]
Out[2]:
                player
           idx
           10
                Messi
           11
              Dembele
           12
               Rafinha
           13
              Cillessen
           14
               Malcom
           15
               Lenalet
           16
               Samper
           17
           18
                 Alba
           19 el Haddadi
          # <font size="4">Какой же в нашей таблице процент заполнения?</font>
          round(filling percentage(barcelona table), 2)
Out[3]: 0.23
```

Доступные операции


```
    Вставка: DirectAddressInsert(Table, key, value) - O(1)
    Удаление: DirectAddressDelete(Table, key) - O(1)
    Поиск: DirectAddressSearch(Table, key) - O(1)
    Псевдокод операций:
    DirectAddressInsert(Table, key, value):
        Table[key] = value
    DirectAddressDelete(Table, key):
        Table[key] = NIL
    DirectAddressSearch(Table, key):
        return Table[key]
    </font>
```

Хэш-функция

Общие характеристики

Хэш-функция используется для отображения множетсва ключей в множетсво хэшей. Их может

h: S → M
 |S| > |M|
 Отображение сюръективно



Требования

Всегда одинаковые значения для одного ключа
Желательно, чтобы ключ с равной вероятностью хэшировался в случайную ячейку

Для допустимого ключа на выходе должна давать натруральное число (+0) в заданном диапазоне

Простейшая хэш-функция

- Хэш-функция через деление с остатком $hash(k) = k \mod M$, где M размер таблицы
- Далее мы разберем другие хеш-функции, в том числе и для работы со строками и последовательностями


Такая хэш-функция хорошо подходит для работы с ключами, которые приводятся к целым числам, и распределены более-менее равномерно.

Коллизии

- Коллизия это ситуация, когда два ключа в результате применения одной хэшфункции дают одно значение хэша.
 В случае с функцией hash(k) = k mod M это одинаковые остатки от деления на
- M.

Разрешение коллизий

Метод цепочек



Сложность операций

Вставка: ChainingInsert(Table, key, value) - O(1)
Удаление: ChainingDelete(Table, key) - O(1) в среднем, O(n) в худшем
Поиск: ChainingSearch(Table, key) - O(1) в среднем, O(n) в худшем
Псевдокод операций:

```
1 М - размер таблицы
2 hash: key → index ∈ {0..M-1}
3
4
5 ChainingInsert(Table, key, value):
6 insert (key, value) at the head of list Table[hash(key)]
7
8
9 ChainingDelete(Table, key):
10 delete (key, value) from the listTable[hash(key)]
11
12
13 ChainingSearch(Table, key):
14 search for an element with key "key" in list Table[hash(key)]
```

Математическое ожидание частоты коллизий и сложность операций

Данный расчет верен для простого равномерного хеширования

• Значения хешей распределяются равномерно

• Хеши вычисляются независимо (т.е. значение хеша не зависит от вычисленных ранее значений)

У хеш-таблиц есть важный параметр α , коэффициент заполнения таблицы $\alpha = n/M$, где M - это количество цепочек, а n - количество записанных значений.

Длины списков в ячейках в сумме = n, так как:

- Всего записей в таблице: $n=n_0+n_1+n_2+\ldots+n_{M-1}$. Матожидание количества записей в цепочке: $E[n_j]=n/M=\alpha$
- Как правило, n > M, следовательно, $\alpha < 1$.

Далее, если операция вычисления хеша и поиска нужной цепочки (корзины) занимает O(1), то отсается найти ожидаемое время поиска элемента в цепочке.

- Элемента нет в списке: поскольку ожидаемая длина равна α , то на промотр цепочки в среднем потребуется α шагов, и +1 на остальные действия, итого $O(1+\alpha)$.
- Элемент есть в списке: ожидаемое количество элементов, которые необходимо просмотреть, так же равно $O(1+\alpha)$.

Если n = O(m) (т.е. количество элементов пропорционально количеству цепочек), то $\alpha = n/m = O(m)/m = O(1)$, и поиск (а вместе с ним и удаление) занимают O(1).

Пример

На изображении используется таблица с $M=12, n=9, hash(k)=k \mod M$

| Hash | Key(s) | | |
|-------------------|--------|----|----|
| 0 | 0 | 12 | |
| 1 | 13 | | |
| 2 | | | |
| 3 | | | |
| 4 | 40 | | |
| 5 | 5 | 17 | 29 |
| 6 | | | |
| 7 | | | |
| 8 | 20 | | |
| 9 | | | |
| 10 | | | |
| 11 | 11 | | |
| a = 9 / 12 = 0.75 | | | |

a = 9 / 12 = 0.75

в начало (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqyILg&expires=1593465693#index)

Демонстрация работы метода цепочек

```
In [4]: demonstrator = demonstrator_gen(barcelona)
```

```
In [5]: try:
    demo = next(demonstrator)
    print(demo) if demo is not None else ""
    except StopIteration:
        print("Just finished")
```

```
0: [(20, 'Roberto')]
1: [(1, 'ter Stegen')]
2: [(2, 'Semedo'), (22, 'Vidal')]
3: [(3, 'Pique'), (23, 'Umtiti')]
4: [(24, 'Vermaelen'), (4, 'Rakitic')]
5: [(5, 'Buskuets')]
6: [(6, 'Denis Suarez'), (26, 'Alena')]
7: [(7, 'Coutinho')]
8: [(8, 'Arthur')]
9: [(9, 'Luis Suarez')]
10: [(10, 'Messi')]
11: [(11, 'Dembele')]
12: [(12, 'Rafinha')]
13: [(13, 'Cillessen')]
14: [(14, 'Malcom')]
15: [(15, 'Lenglet')]
16: [(16, 'Samper')]
17: []
18: [(18, 'Alba')]
19: [(19, 'el Haddadi')]
```

Псевдокод операций


```
Вставка: `ChainingInsert(Table, key, value)` - O(1)
Удаление: `ChainingDelete(Table, key)` - O(1) в среднем, O(n) в худшем
Поиск: `ChainingSearch(Table, key)` - O(1) в среднем, O(n) в худшем
Псевдокод операций:
М - размер таблицы
hash: key → index ∈ {0..M-1}
ChainingInsert(Table, key, value):
insert (key, value) at the head of list Table[hash(key)]
ChainingDelete(Table, key):
delete (key, value) from the Table[hash(key)]
ChainingSearch(Table, key):
Search for an element with key "key" in list Table[hash(key)]
```

в начало (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqylLg&expires=1593465693#index)

Открытая адресация

Основной принцип

- Идея: выбрать алгоритм (probing), по которому будет выбираться следующая ячейка, если произошла коллизия
 Искать записи при помощи того же алгоритма
- Раширять таблицу, когда она заполнится достаточно сильно (load factor)



Сложности

- Выбор хэш-функции, пробинга Образование кластеров Операция удаления

Виды пробинга

Есть несколько основных видов пробинга, от сосвсем простых до более сложных. Это, например,

- Линейный пробинг
- Квадратичный пробинг
- Двойное хэширование

Они различаются количеством вариантов обхода при поиске и "равномерностью" распределения данных по массиву.

Для того, чтобы понять, как работают таблицы, мы рассмотрим линейный пробинг, а потом перейдем к другим видам пробинга и сравним их.


Линейный пробинг

- $hash(k, i) = (hash'(k) + i) \mod M$
- hash'(k,i) вспомогательная хэш-функция (например, остаток от деления)
- Неравномерно, склонно к образованию кластеров
- Чем больше кластер, тем быстрее он растет: (s+1)/M, где s размер кластера

На иллюстрации используется хеш-таблица с разщмером M=12

- желтые квадраты "сдвинутые" ключи
- зеленые ключи на "своих" местах

На иллюстрации ошибка: на самом деле, вероятность увеличения кластеров = 1/3, 5/12, 1/6!



Псевдокод операций

- Вставка: `OpenAddressInsert(Table, key, value)` O(1) в среднем, O(n) в худшем Поиск: `OpenAddressSearch(Table, key)` O(1) в среднем, O(n) в худшем Удаление: `OpenAddressDelete(Table, key)` O(1) в среднем, O(n) в худшем

- Псевдокод операций (шаг i=1):

```
М - размер таблицы
2
   hash: key \rightarrow index \in \{0..M-1\}
4
5
6
7
8
9
10
   OpenAddressInsert(Table, key, value)
        i = 0
        repeat
             j = hash(key, i)
             if Table[j] == NIL
                 return j
             else:
11
12
                  i = i + 1
13
        until i == m
14
        return "overflow"
15
16
17 OpenAddressSearch(Table, key)
        i = 0
18
19
20
        repeat
             j = hash(key, i)
21
             if Table[j] == key
22
23
                  return j
        i = i + 1

until T[j] == NIL or i == m
24
25
        return NÍL
```


Удаление?

- Создавать дополнительный массив "данные удалены" (замедляет поиск, "п ортит" _load factor_)
- Пропускаем ячеки с другим хэшем; значение с первым совпадающим ключом к опируем в текущую ячейку; удаляем его. Однако на практике такой подход не используется из-за его высокой сложности и не слишком высокой эффек тивнсоти. Кроме того, он плозо работает со сложными схемами пробинга.

Разбор удаления при открытой адресации

```
М - размер таблицы
1
2
3
4
5
6
7
8
9
10
11
    hash: key \rightarrow index \in \{0..M-1\}
    OpenAddressInsert(Table, key, value)
          i = 0
          repeat
                j = hash(key, i)
if Table[j] == NIL or Table[j] == DELETED:
    return j
                else:
12
                      i = i + 1
13
          until i == m
14
          return "overflow"
15
16
17
18
19
20
21
22
23
24
25
26
27
28
29
31
33
33
    OpenAddressSearch(Table, key)
          i = 0
          repeat
                j = hash(key, i)
if Table[j] == key
                      return j
          i = i + 1


until T[j] == NIL or i == m
          return NIL
   OpenAddressDeleted(Table, key)
          i = 0
          repeat
                j = hash(key, i)
if Table[j] == DELETED
    return j
                i = i + 1
```

35 until T[j] == NIL or i == m
36 return NIL

"Ленивое" удаление

- Во время поиска элемента запомнить первый индекс, где попалось DELETED (если такой встретился)
- Поменять первый найденный DELETED с найденным элементом местами это в будущем ускорит поиск
- Я не очень понимаю, почему такая схема называется "ленивой", с ленивыми вычислениями тут мало общего

Используется практически та же таблица, что и на прошлых изображениях. Кра сные квадраты - удаленные данные.



Paccмотрим удаление на примере практической реализации общего назначнения - dictobject.c языка Python.

Sentinel для удаленных значений - DKIX_DUMMY:

```
Dummy. index == DKIX_DUMMY (combined only)
   Previously held an active (key, value) pair, but that was dele
ted and an
   active pair has not yet overwritten the slot. Dummy can trans
ition to
   Active upon key insertion. Dummy slots cannot be made Unused
again
   else the probe sequence in case of collision would have no way
to know
   they were once active.
```

Код метода dict_popitem (dict.pop(key)), который удаляет и возвращает эл емент по ключу:

```
static PyObject *
    dict_popitem(PyDictObject *mp, PyObject *Py_UNUSED(ignored))
1234567
         Py_ssize_t i, j;
PyDictKeyEntry *ep0, *ep;
         PyObject *res;
         res = PyTuple_New(2);
8
         if (res = NULL)
9
               return NULL;
10
         if (mp->ma used == 0) {
             Pv DECREF(res);
11
12
             PyErr SetString(PyExc KeyError,
13
                                    "popiTem(): dictionary is empty");
14
              return NULL;
15
        /* Convert split table to combined table */
if (mp->ma_keys->dk_lookup == lookdict_split) {
   if (dictresize(mp, DK_SIZE(mp->ma_keys))) {
16
17
18
19
                   Py_DECREF(res);
20
21
22
23
24
25
26
27
28
29
31
32
33
34
                   return NULL;
             }
        ENSURE_ALLOWS_DELETIONS(mp);
        /* Pop last item */
ep0 = DK_ENTRIES(mp->ma_keys);
        i = mp->ma_keys->dk_nenTries - 1;
        while (i \ge 0 \& ep\overline{0}[i].me_value == NULL) {
             i--;
        assert(i >= 0);
        ep = &ep0[i];
j = lookdict_index(mp->ma_keys, ep->me_hash, i);
```

```
35
        assert(j >= 0);
        assert(dictkeys_get_index(mp->ma_keys, j) == i);
dictkeys_set_index(mp->ma_keys, j, DKIX_DUMMY);
36
37
38
39
        PyTuple_SET_ITEM(res, 0, ep->me_key);
PyTuple_SET_ITEM(res, 1, ep->me_value);
40
        ep->me_Key = NULL;
ep->me_value = NULL;
41
42
43
        /* We can't dk_usable++ since there is DKIX_DUMMY in indice
s */
44
        mp->ma_keys->dk_nentries = i;
45
        mp->ma_used--;
46
        mp->ma_version_tag = DICT_NEXT_VERSION();
47
        assert(_PyDict_CheckConsistency(mp));
48
        return res;
49 }
```

А вот так выглядит Search:

```
static Py ssize t
2
    lookdict_index(PyDictKeysObject *k, Py_hash_t hash, Py_ssize_t
index)
3 {
         size_t mask = DK_MASK(k);
size_t perturb = (size_t)hash;
size_t i = (size_t)hash & mask;
4
5
6
7
         for (;;) {
    Py_ssize_t ix = dictkeys_get_index(k, i);
    if (ix == index) {
89
10
11
12
13
               if (ix == DKIX EMPTY) {
14
                     return DKIX_EMPTÝ;
15
               perturb >>= PERTURB SHIFT;
16
17
               i = mask \& (i*5 + perturb + 1);
18
         Py UNREACHABLE();
19
20 }
```

В принципе, ничего особенного, кроме схемы сдвига, зедсь нет - это практич ески псевдокод, переведенный на С.

<u>в начало (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b6 le.html?hash=okvx7MOSeqh5taAlDqyILg&expires=1593465693#index)</u>

Виды пробинга

Линейное исследование

Было разобрано выше (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html?hash=okvx7MOSeqh5taAlDqylLg&expires=1593465693#problin)

Квадратичное исследование

- $hash(k, i) = (hash'(k) + c_1i + c_2i^2) \mod M$.
- Лучше линейного, но нужно подбирать $\mathbf{c}_1, \mathbf{c}_2, M$.

Несколько популярных вариантов выбора констант

- $hash(k) = (hash'(k) + i^2) \mod M$, где $c_1 = 0, c_2 = 1, M \text{простое} > 3$, фактор заполнения $\alpha < 1/2$
- $hash(k) = (hash'(k) + (i + i^2) / 2) \mod M$, где $c_1 = c_2 = 1/2, M = 2^k$
- $hash(k) = (hash'(k) + -1^i \cdot i^2) \mod M$, где $M \equiv 3 \mod 4$

Почему $\alpha < 1/2$? Пусть есть x и y, указывающие на одну локацию, но $x \neq y$, и $0 \leq x, y \leq M/2$.

$$hash(k) + x^{2} \equiv hash(k) + y^{2} modM$$
$$x^{2} \equiv y^{2} modM$$
$$x^{2} - y^{2} \equiv modM$$
$$(x - y) \cdot (x + y) \equiv modM$$

 $x - y \neq 0, x + y \neq 0$ - значит, существует M/2 различных мест для записи.

Двойное хэширование

- $hash(k, i) = (hash_1(k) + i \times hash_2(k)) \mod M$.
- Дает m^2 возможных последовательностей, более равномерно
- Значение $hash_2(k)$ всегда должно быть взаимно простым с M (для обхода всей
 - как вариант, для достаточно большого M:
 - \bullet $h_1(k) = k \mod M$
 - $h_2(k) = 1 + (k \mod (M-1))$

в начало (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqyILg&expires=1593465693#index)

Домашняя работа

- Домашняя работа одна на всю неделю. Это первая половина, которую можно начать выполнять сейчас.
- Вторая половина будет после занятия в среду.
- 1. Реализовать хеш-таблицу, использующую метод цепочек
- дополнительно: для хранения внутри цепочек при достижении значительного числа элементов (~32) заменять их на BST 2. *Или*: реализовать хеш-таблицу с открытой адресацией
- - дополнительно: реализовать "ленивое" удаление реализовать квадратичный пробинг

Краткая справка

C++

`std::unordered_map` Метод цепочек - для универсальноси https://bit.ly/2RNxPnD (в другом разделе ссылка дублируется) Можно "легко" сделать под свои нужды

Java 8

- `java.util.HashMap`
- Метод цепочекИспользуются деревья внтури одной корзины

C#

- `System.Collections.Hashtable` и `System.Collections.Generic.Dictionary`
 Hashtable: открытая адресация, двойное хэширование
 Dictionary: метод цепочек
 https://bit.ly/2C0ryPW (в другом разделе ссылка дублируется)

в начало (https://otus.ru/media-private/37/b6/hash_tables_intro-31272-37b61e.html? hash=okvx7MOSeqh5taAlDqyILg&expires=1593465693#index)

Ссылки

Python

ссылка на код [dictobject.c] (https://hg.python.org/cpython/file/52f68c95e025/Objects/dictobject.c#l33) [как выбиралась реализация] (https://github.com/python/cpython/blob/master/Objects/dictnotes.txt) [Просто хорошая статья на английском с пояснениями исходного кода dict()] (https://www.laurentluce.com/posts/python-dictionary-implementation/)

C++

Тут стоит обратить внимание на комментарии
 [std::unordered_map](https://gcc.gnu.org/onlinedocs/libstdc++/libstdc++-html-USERS-4.1/unordered_map-source.html)
 [hashtable](https://gcc.gnu.org/onlinedocs/libstdc++/libstdc++-html-USERS-4.1/hashtable-source.html)

Почему именно так - [по ссылке](http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2003/n1456.html). Стена текста!

Java

Подробности про реализацию корзин в `java.utils.HashMap` [тут]
 (http://hg.openjdk.java.net/jdk8/jdk8/jdk/file/687fd7c7986d/src/share/classes/java/util/HashN
 (комментарии к исходнику)

C#

- Повторение [ссылки](https://bit.ly/2C0ryPW) выше объяснение реализации HashTable и Dictionary
 Исходник [HashTable] (https://references.microsoft.com/#mscorlib/system/collections/hashtable.cs)
- Исходник [Dictionary] (https://referencesource.microsoft.com/#mscorlib/system/collections/generic/dictionary.cs)

| In []: | |
|---------|--|
| In []: | |
| In []: | |
| In []: | |